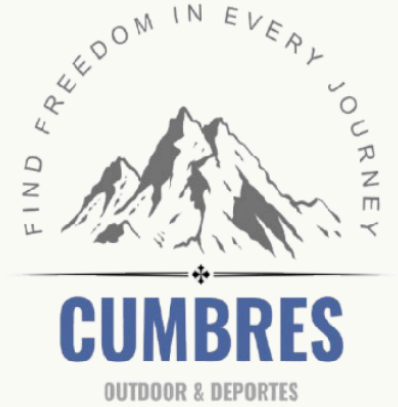
PROYECTO END-TO-END · DATOS PARA DECISIONES ESTRATÉGICAS



DIAGNÓSTICO Y ANÁLISIS DE DATOS

PARA CUMBRES OUTDOOR & DEPORTES

Martina Cottura

Proyecto End-to-End · Datos para Decisiones Estratégicas

Julio 2026

RECORRIDO ANALÍTICO END-TO-END

Del dato crudo al insight de negocio: contexto de negocio, arquitectura de datos, preparación en Python y modelado en MySQL, hasta los hallazgos que orientan la toma de decisiones.

CONTEXTO → ARQUITECTURA → PYTHON → MYSQL → INSIGHTS

PYTHON	MYSQL	POWER BI
Preparación de datos	Modelado analítico	Dashboard ejecutivo

Martina Cottura

Cumbres Outdoor & Deportes · Customer Analytics · Julio 2026

ÍNDICE

Resumen ejecutivo **5**
1. Contexto de negocio **5**
2. Diseño del dataset y objetivos analíticos **6**
2.1 Construcción del dataset 6
2.2 Objetivo general 6
2.3 Objetivos específicos 6
2.4 Preguntas analíticas 7
3. Arquitectura analítica **7**
3.1. Sistemas de origen (simulados) 7
3.2. Preparación analítica 7
3.3. Persistencia y modelado 8
3.4. Consumo analítico 8
4. Preparación de datos en Python **8**
4.1 Preservación de los datos originales 8
4.2 Evaluación de la calidad de los datos 8
4.3 Limpieza y transformación 9
4.4 Feature Engineering 9
4.5 Preparación para MySQL 11
4.6 Resultado de la etapa 11
5. Modelado relacional en MySQL **11**
5.1 Modelo entidad-relación 11
5.2 Integridad y relaciones 13
5.3 Preparación para el consumo analítico 13
5.4 Capa de vistas analíticas 13
5.5 Alcance del indicador de riesgo 14
6. Modelo analítico y visualización en Power BI **14**
6.1 Preparación del modelo analítico 14
6.2 Desarrollo del dashboard 15
6.3 Página 3: ¿A quién reactivar primero? 17
6.4 Resultado de la etapa 18
7. Business Insights 18
7.1 La facturación de 2025 se mantiene estable: la leve caída viene de menos compradores activos 19
7.2 El liderazgo del canal online depende de una decisión de imputación 19
7.3 Cuatro de cada diez euros dependen del 16% de los clientes 19
7.4 El universo en riesgo es amplio en clientes y acotado en facturación 20
7.5 Hay 97 clientes ya captados que nunca llegaron a comprar 20
7.6 81 clientes concentran casi dos tercios del valor en riesgo 20
8. Recomendaciones 20
8.1 Líneas de acción por segmento RFM 21
8.2 Acciones por tienda y canal 22
8.3 KPIs de seguimiento del plan 22
9. Limitaciones y consideraciones a futuro 23

9.1 Limitaciones del proyecto 23
9.2 Próximas fases del proyecto 24
10. Anexo **25**
A. Diccionario de datos 25
B. Capa SQL: consultas, vistas y reconciliación 26
C. Índice de Medidas DAX 28

Resumen ejecutivo

Este documento describe una solución completa de Customer Analytics construida sobre un pipeline Python → MySQL → Power BI. El caso analiza la base de clientes de un retailer

omnicanal de equipamiento deportivo con cuatro tiendas físicas y un canal online: 1.000 clientes registrados, 8.000 transacciones y €1.640.308 de facturación entre 2023 y 2025. El historial 2023-2025 se usa para construir una fotografía de la cartera al 1/1/2026, sobre la que se identifica un universo de clientes en riesgo, se dimensiona su valor económico y se proponen iniciativas de reactivación. Los datos son sintéticos.

Indicador	Valor	Lectura
Clientes compradores	**903 de 1.000**	El 9,7% de la base registrada nunca completó una compra.
Facturación 2023-2025	**€1.640.308**	Ticket medio de €205 y 8,86 compras por comprador. Caída moderada en 2025 (−3,4%).
Concentración de valor	**41,7% en el 16,5%**	149 clientes de Alto Valor aportan €684.150. Índice de concentración de 2,53 sobre la base compradora.
Clientes en riesgo	**269 (29,8%)**	Más de 234 días sin comprar al 1/1/2026 (percentil 70 de la recencia). Criterio de priorización, no predicción de abandono (apartado 5.5).
Facturación de clientes en riesgo	**€182.755 (11,1%)**	Facturación 2023-2025 de los clientes hoy en riesgo; en 2025 aportaron solo el 4,1%. El 62,7% de ese importe se concentra en 81 clientes.

Tres conclusiones sostienen las recomendaciones. La primera es que el valor del cliente lo construye la frecuencia y no el importe: el ticket medio es prácticamente idéntico en los tres segmentos, de modo que la diferencia entre un cliente de €4.592 y uno de €796 está en cuántas veces vuelve, y la brecha se mantiene en 4,5 veces al controlar por el tiempo que cada cliente lleva comprando. La segunda es que el universo en riesgo es amplio en número de clientes pero acotado en dinero, y está muy concentrado: 81 clientes explican casi dos tercios de la facturación asociada a clientes en riesgo, lo que convierte una campaña masiva en una acción dirigida. La tercera es que existe una bolsa de 97 clientes ya captados que nunca compraron, una oportunidad de ciclo corto pero de alcance acotado, del orden de €6.600.

1. Contexto de negocio

Cumbres Outdoor & Deportes es una empresa ficticia del sector retail especializada en la comercialización de equipamiento deportivo y productos para actividades outdoor. Opera bajo un modelo omnicanal que integra cuatro tiendas físicas: Madrid, Barcelona, Valencia y Sevilla, con un canal de comercio electrónico de alcance nacional.

La organización comercializa productos pertenecientes a cuatro líneas de negocio: Montaña y Trekking, Running y Trail, Ciclismo y Pádel. Como parte de su operación diaria registra información sobre clientes, transacciones, productos y puntos de venta (Barcelona, Madrid, Sevilla, Valencia y tienda online), generando un histórico de datos que constituye la base para el análisis del comportamiento de compra.

A pesar de disponer de información transaccional, la empresa enfrenta una situación habitual en muchas organizaciones: los datos existen, pero no se transforman sistemáticamente en conocimiento para la toma de decisiones. Las acciones comerciales continúan apoyándose principalmente en indicadores descriptivos de ventas, sin una

comprensión integral del valor de los clientes, sus patrones de compra o su riesgo de abandono.

2. Diseño del dataset y objetivos analíticos

2.1 Construcción del dataset

Al no disponer de información empresarial real, se diseñó un conjunto de datos sintético utilizando Python con el propósito de reproducir un escenario representativo de una empresa de retail omnicanal.
Antes de generar los registros, se definió el modelo de negocio que se pretendía simular, estableciendo las principales entidades, sus atributos y las relaciones entre ellas. Sobre esta base se construyó un dataset compuesto por cuatro tablas principales: clientes, transacciones, productos y tiendas.
Con el objetivo de aproximar el proyecto a un escenario real de análisis de datos, también se introdujeron de forma controlada diferentes situaciones de calidad de datos, entre ellas valores nulos, errores de registro e inconsistencias en determinados campos.

2.2 Objetivo general

Desarrollar una solución integral de Customer Analytics que transforme datos transaccionales en información útil para la toma de decisiones comerciales, permitiendo comprender el comportamiento de los clientes, identificar oportunidades de fidelización y detectar a los clientes en riesgo.

2.3 Objetivos específicos

- Diseñar un pipeline analítico reproducible desde la generación del dato hasta su visualización.
- Preparar y validar los datos mediante procesos de limpieza, transformación y control de calidad en Python.
- Construir indicadores de comportamiento de clientes mediante la metodología RFM y la identificación de clientes en riesgo.
- Modelar la información en una base de datos relacional utilizando MySQL.
- Desarrollar un modelo semántico y un dashboard ejecutivo en Power BI para facilitar el análisis y la toma de decisiones.
- Obtener insights de negocio que permitan proponer acciones concretas de retención, fidelización y crecimiento.

2.4 Preguntas analíticas

El análisis se organiza en torno a las siguientes preguntas de negocio:

- ¿Cómo se distribuye el valor de la cartera de clientes?
- ¿Qué segmentos concentran mayor facturación?
- ¿Qué clientes presentan mayor inactividad al 1/1/2026?

- ¿Qué valor económico representa el universo en riesgo?
- ¿Cómo se distribuye el comportamiento por tienda y canal?
- ¿Qué oportunidades de reactivación pueden plantearse?

La composición de canasta por segmento queda como trabajo futuro (apartado 9.2).

3. Arquitectura analítica

La solución fue diseñada siguiendo una arquitectura analítica por capas, en la que cada herramienta cumple una responsabilidad específica dentro del pipeline de datos. El objetivo principal fue garantizar un flujo de trabajo reproducible, trazable y fácilmente escalable, evitando duplicar lógica de negocio entre las distintas etapas del proyecto.

Si bien el proyecto utiliza un dataset sintético generado mediante Python, la arquitectura propuesta busca simular un escenario habitual en organizaciones del sector retail. En un entorno productivo, la información utilizada para el análisis provendría de distintos sistemas operacionales, principalmente un **ERP (Enterprise Resource Planning)**, encargado de registrar las transacciones comerciales, productos y puntos de venta, y un **CRM (Customer Relationship Management)**, responsable de administrar la información de clientes y su relación con la empresa.

La arquitectura se estructura en cuatro capas principales:

3.1. Sistemas de origen (simulados)

La primera capa representa los sistemas transaccionales del negocio. En este caso, los datos fueron generados mediante Python para simular la información que normalmente sería producida por un ERP y un CRM, incluyendo clientes, transacciones, productos y tiendas bajo reglas de negocio consistentes.

3.2. Preparación analítica

Python constituye la primera capa de procesamiento. Sobre los datos generados se ejecutan los procesos de evaluación de calidad, limpieza, transformación, enriquecimiento y construcción de variables analíticas. El resultado es un conjunto de datos consistente y preparado para su persistencia.

3.3. Persistencia y modelado

Los datasets preparados se cargan en MySQL, donde se implementa el modelo relacional del proyecto mediante un esquema estrella. Esta capa concentra la persistencia de la información, la definición de relaciones entre entidades y la validación de la integridad referencial.

Sobre ese esquema se construyó además una capa de vistas analíticas (apartado 5.4) para resolver en SQL la explotación analítica sin reescribir los JOIN en cada consulta. Power BI no las usa: se conecta directamente a las tablas del modelo dimensional en modo Import, decisión razonable dado el reducido volumen de datos.

3.4. Consumo analítico

La última capa corresponde a Power BI, donde se construye el modelo semántico, se desarrollan las medidas DAX y se implementa el dashboard ejecutivo utilizado para el análisis del comportamiento de clientes y la generación de insights de negocio.

4. Preparación de datos en Python

Python constituye la primera etapa del pipeline analítico y concentra la totalidad de las transformaciones realizadas sobre los datos antes de su persistencia.

4.1 Preservación de los datos originales

Los archivos generados inicialmente representan la capa **raw** del proyecto y se conservaron sin modificaciones durante todo el proceso de desarrollo.

A partir de estos datos originales se construyó una nueva capa **clean**, sobre la cual se aplicaron todas las tareas de limpieza, transformación y enriquecimiento necesarias para el análisis, con trazabilidad completa de las transformaciones.

Como resultado de esta etapa se obtuvieron los siguientes datasets:

- **clientes_clean.csv**
- **transacciones_clean.csv**
- **productos_clean.csv**
- **tiendas_clean.csv**

4.2 Evaluación de la calidad de los datos

Sobre los datasets originales se realizó un diagnóstico de calidad para identificar valores faltantes, inconsistencias y anomalías incorporadas deliberadamente durante la construcción del dataset sintético.

A partir de esta evaluación se definieron los criterios de tratamiento para cada situación detectada, diferenciando aquellas que requerían corrección de aquellas que representaban información válida del negocio, como las devoluciones de productos.

Una revisión posterior detectó una anomalía que el diagnóstico inicial no había identificado: 739 de los 903 compradores registran compras anteriores a su fecha_alta. El campo no se corrigió, porque el dataset no contiene una fecha de registro alternativa, y no se utiliza para

medir antigüedad real, cohortes de adquisición ni tiempo desde el alta. No afecta el cálculo de recencia, que parte de la fecha de la última compra; cuando se necesita medir exposición temporal se toma como inicio la primera compra observada.

4.3 Limpieza y transformación

El diagnóstico detectó cuatro situaciones que requerían una decisión. En todas se buscó primero el patrón y después se corrigió, para distinguir un error de origen de un comportamiento legítimo del negocio.

Importes multiplicados por 8: 146 transacciones tenían importes fuera del dominio del catálogo —valor absoluto superior a €400—, con una cola que llegaba a €3.198 y equivalía al 14% de la facturación bruta. El patrón corresponde a un error de registro en caja con un factor conocido, de modo que se corrigió dividiendo por 8 y conservando el signo. Tras la corrección, ningún importe supera los €400.

Transacciones sin punto de venta: 240 transacciones (3%) no tenían store_id. Se reparten de forma uniforme entre 2023 y 2025 (entre 3 y 11 por mes). Se imputaron a T05 · Web, el punto de venta online del catálogo; el efecto de esa imputación sobre la lectura del canal se analiza en el apartado 7.2.

Devoluciones: 80 transacciones (1%) tienen importe negativo y se reparten de forma pareja entre los cinco puntos de venta, entre el 0,8% y el 1,2% de cada uno. Se conservaron como parte legítima de la venta: la facturación del informe es neta de devoluciones, y esas filas se cuentan como transacciones en las métricas de frecuencia (anexo C).

Nulos en datos de contacto: email (40 registros) y ciudad (50) presentan nulos sin patrón. Como ninguno de los dos campos interviene en el análisis, se conservaron sin imputar.

Se verificó además que no hay registros duplicados en ninguna tabla y que todos los identificadores de cliente, producto y tienda de las transacciones existen en su dimensión.

4.4 Feature Engineering

Una vez finalizado el proceso de limpieza se construyeron las variables analíticas del proyecto.

A partir de la integración entre las tablas de clientes y transacciones se calcularon las métricas de **Recency**, **Frequency** y **Monetary (RFM)** para cada cliente, así como el indicador de riesgo.

Todas las métricas se calculan contra una fecha de referencia fija, el 1 de enero de 2026 (el día siguiente a la última transacción registrada), declarada en el código. Esa fecha es una fecha de corte operativa: el historial 2023-2025 se usa para construir una fotografía de la cartera y la recencia de cada cliente es el número de días entre el 1/1/2026 y su última

compra. 2025 es el último año histórico de esa fotografía, no un período de análisis separado. La fecha se controla también en MySQL (control 10.3 del anexo B).

El cálculo se resolvió en tres pasos con decisiones diferenciadas. El primero puntúa cada dimensión en quintiles sobre los 903 clientes con historial de compra, asignando valores de 1 a 5. En Recency la escala se invierte —menos días equivale a mejor puntuación—, de modo que quien compró recientemente obtiene un 5. En Frequency los quintiles se calcularon sobre el rango de la variable y no sobre su valor, porque la frecuencia es un entero con pocos valores distintos y los empates impiden repartir la población en grupos equilibrados. Los empates se resuelven por orden de aparición (rank con método first) sobre la tabla ordenada por customer_id, de modo que la asignación es reproducible.

El segundo paso agrupa los clientes en segmentos comerciales. La clasificación no reparte la población en proporciones fijas, sino que aplica reglas sobre los scores: el valor se resume en la suma de Frequency y Monetary —un índice de 2 a 10— y se combina con Recency. Alto Valor exige un índice de valor de 9 o superior **y** un score de Recency de 4 o 5; Bajo Valor se asigna cuando el índice de valor es 5 o inferior **o** cuando el score de Recency es 1 o 2; el resto conforma Medio Valor. De ahí resultan los 149, 267 y 487 clientes de cada segmento.

Esta construcción tiene una consecuencia directa: la condición sobre Recency aparece en ambos extremos de la regla. Un cliente inactivo cae en Bajo Valor aunque su gasto acumulado sea alto, y ningún cliente de Alto Valor puede estar inactivo, porque la actividad reciente es requisito de entrada al segmento. La distribución del riesgo por segmento que de ahí resulta se analiza en el apartado 5.5.

El tercer paso define el indicador de riesgo, una decisión independiente de la segmentación. Un cliente se considera en riesgo cuando su recencia supera el percentil 70 de la distribución de recencia de los 903 compradores, que con esta fecha de referencia es de 234 días (sin compra desde antes del 12 de mayo de 2025). Los 97 registros sin transacciones quedan fuera del indicador, porque no pueden abandonar una relación que nunca iniciaron. El umbral se calcula en el código y no se escribe a mano. En este informe «en riesgo» designa esa condición de inactividad elevada y no un abandono consumado: el dataset no contiene una variable observada de abandono.

El umbral se ancla en un percentil, y no en un plazo fijo, porque el dataset no permite observar el ciclo de recompra real y la ventana de observación es acotada (recencia máxima de 1.096 días). El percentil 70 deja en riesgo al 30% más inactivo de los compradores; es un corte relativo, válido para esta fecha de referencia, que debe recalcularse si esta cambia (apartado 9.1).

El resultado de este proceso fue la generación de un nuevo dataset analítico:

- **clientes_rfm.csv**

4.5 Preparación para MySQL

Como última etapa, todos los datasets fueron adaptados al formato requerido por MySQL mediante la normalización de tipos de datos, formatos de fechas y estructura de los archivos CSV. En concreto, los enteros se exportan sin parte decimal, los importes con punto decimal y dos decimales fijos —acordes con DECIMAL(10,2)—, las fechas en formato ISO (AAAA-MM-DD), en codificación UTF-8 y sin la columna de índice de pandas. Antes de exportar se verifica además que no haya nulos y que la longitud máxima de cada campo de texto quepa en el VARCHAR definido en la DDL.

Los cinco archivos —los cuatro *_clean.csv y clientes_rfm.csv— se cargaron en MySQL para construir el modelo entidad-relación (capítulo 5).

4.6 Resultado de la etapa

La preparación de datos produjo un conjunto de datasets limpios, consistentes y enriquecidos, listos para su persistencia en una base de datos relacional.

La etapa se reejecutó desde cero a partir de clientes_clean.csv y transacciones_clean.csv, con la fecha de referencia fija. El resultado coincide con las cifras publicadas (903 compradores; 149, 267, 487 y 97 clientes por segmento; 269 en riesgo) y con la tabla clientes_rfm cargada en MySQL.

5. Modelado relacional en MySQL

Una vez finalizada la etapa de preparación en Python, los datasets fueron cargados en MySQL para construir la capa de persistencia del proyecto.

A diferencia de la etapa anterior, en MySQL no se realizaron procesos de limpieza ni transformación de datos. Todas las reglas de calidad y enriquecimiento se implementaron previamente en Python.

5.1 Modelo entidad-relación

El modelo de datos fue diseñado siguiendo un esquema estrella (*Star Schema*). La estructura quedó conformada por una tabla de hechos que almacena las transacciones comerciales y cuatro tablas de dimensiones que describen el contexto del negocio. Los nombres que siguen son los físicos implementados en MySQL, los mismos que utilizan las consultas del anexo B y el modelo semántico de Power BI:

Tabla de hechos

- transacciones (tabla de hechos)

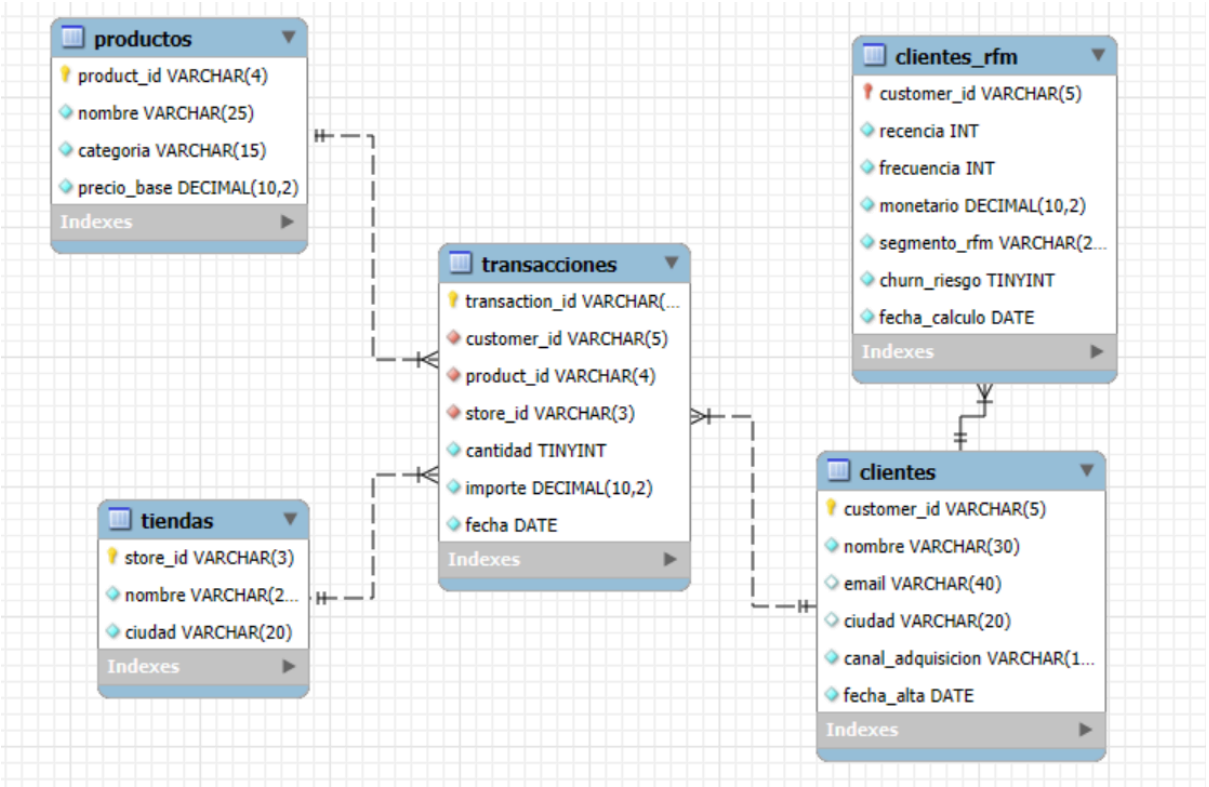
Tablas de dimensiones

- clientes

- productos
- tiendas
- clientes_rfm

La dimensión **clientes_rfm** incorpora las variables analíticas calculadas previamente en Python, incluyendo las métricas de Recency, Frequency y Monetary, la clasificación por segmentos y el indicador de riesgo.

Por lo tanto, el modelo Entidad- Relación quedó configurado de la siguiente manera:



5.2 Integridad y relaciones

Durante la implementación se definieron las claves primarias y foráneas necesarias para garantizar la consistencia entre las entidades del modelo.

La tabla de transacciones se vincula con clientes, productos y tiendas mediante relaciones de muchos a uno, y clientes_rfm se vincula con clientes en una relación uno a uno sobre customer_id. En Power BI se suma la relación de la tabla Calendario con la fecha de la transacción. Todas filtran en una sola dirección, de la dimensión hacia los hechos, salvo la relación uno a uno entre clientes_rfm y clientes, que es bidireccional. Las medidas que

atraviesan la tabla de hechos neutralizan explícitamente el contexto de tienda y fecha (anexo C).

5.3 Preparación para el consumo analítico

El modelo relacional desarrollado en MySQL constituye la fuente de datos utilizada por Power BI para construir el modelo semántico del proyecto.

Power BI se conecta directamente al esquema estrella en modo Import (apartado 3.3), sin interponer la capa de vistas, que cumple un propósito distinto y se documenta en el apartado siguiente.

5.4 Capa de vistas analíticas

La explotación analítica en SQL se resolvió con ocho vistas sobre el esquema estrella, que devuelven el resultado ya agregado al grano de cada pregunta de negocio del apartado 2.4. El criterio que las gobierna es que no calculan lógica de negocio: la segmentación RFM y el indicador de riesgo se calculan una única vez en Python y se persisten en clientes_rfm; SQL agrega, cruza y expone. El script ejecutable está en views_customer_analytics.sql del repositorio y las decisiones de construcción no evidentes se recogen en el apartado B.1.

La correspondencia entre preguntas analíticas y vistas es la siguiente:

Pregunta analítica (2.4)	Vista	Qué expone
Cómo se distribuye el valor de la cartera de clientes	v_distribucion_cartera	Tamaño y peso económico de cada segmento, participación acumulada e índice de concentración (cuántas veces pesa más un segmento en facturación que en número de compradores).
Qué segmentos concentran mayor facturación	v_contribucion_segmento_anio	Facturación real por segmento y ejercicio sobre la tabla de hechos, con la participación de cada segmento dentro de su año.
Qué clientes presentan mayor inactividad al 1/1/2026 y qué valor representan	v_retencion_prioridad · v_rfm_cliente	Cartera en riesgo ordenada por facturación histórica y repartida en deciles; detalle por cliente para contrastar en SQL las cifras de riesgo de las páginas 2 y 3.
Cómo se distribuye el comportamiento por tienda y canal	v_categoria_tienda · v_temporal_tienda	Mix de categorías por plaza e índice de sobre-indexación, y evolución mensual de la facturación por punto de venta. El desglose se limita a métricas de facturación por el motivo expuesto en el apartado 9.1.
Qué oportunidades de reactivación pueden plantearse	v_adquisicion_conversion	Tasa de conversión, clientes no convertidos y valor por canal de captación.

Además, v_hechos_transacciones es una vista plana con una fila por transacción, para exploración y validación cruzada; no es fuente del modelo semántico (apartado 5.3). Ninguna vista con grano de punto de venta expone métricas de cliente, porque un mismo comprador opera en varias plazas y sumar clientes por tienda devuelve vínculos y no

personas (apartado 9.1). El canal (web frente a tienda física) no es dimensión de análisis: la comparación entre ambos no mostró diferencias materiales (control 10.9 del anexo B).

5.5 Alcance del indicador de riesgo

El umbral de 234 días (percentil 70 de la recencia de los 903 compradores al 1/1/2026) se obtuvo con el historial completo 2023-2025, por lo que no puede validarse contra el propio período: es un criterio de priorización, no un indicador validado de abandono. Además, la recencia interviene en el score RFM y a la vez define el umbral, de modo que la distribución del riesgo por segmento —0% en Alto y Medio Valor, 55,24% en Bajo Valor— es una consecuencia aritmética del diseño y no un hallazgo comercial. Por la misma razón, los 81 clientes prioritarios de la página 3 del dashboard (apartado 6.3) pertenecen todos al segmento Bajo Valor: su etiqueta de segmento refleja la inactividad, no el volumen de compra acumulado.

El indicador identifica una población de inactividad elevada, no un abandono consumado, y por eso la reactivación se prioriza por valor (apartado 6.3 y capítulo 8).

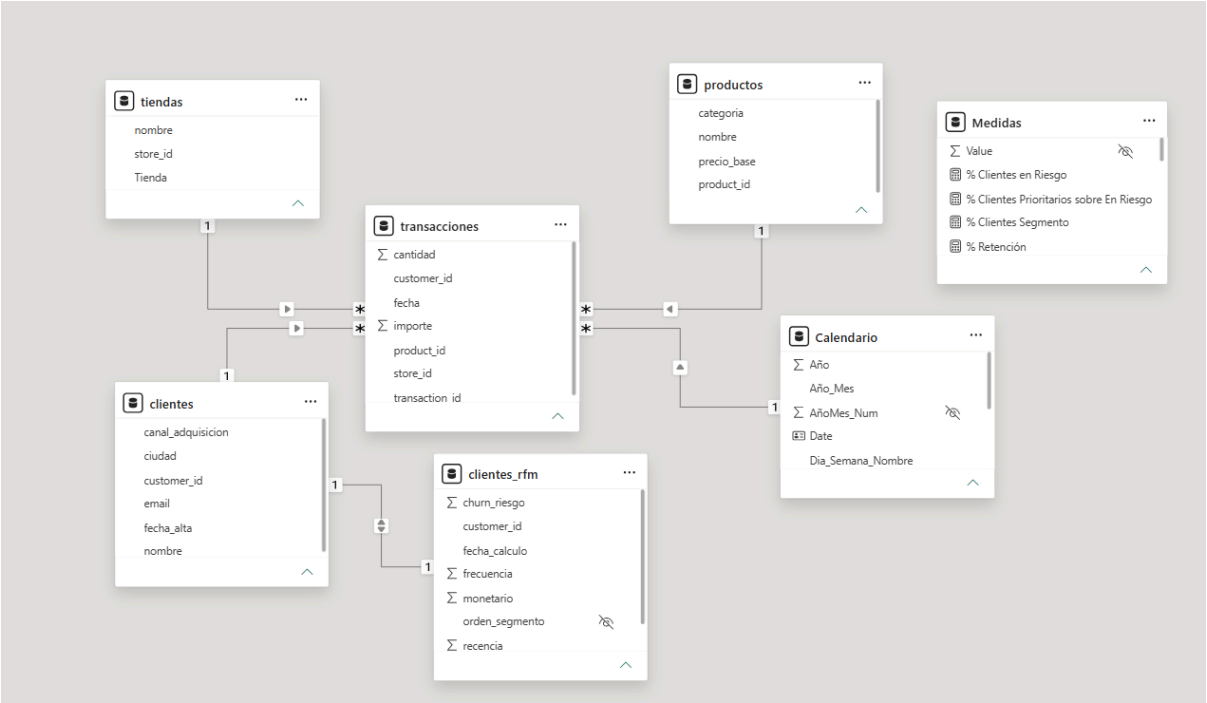
6. Modelo analítico y visualización en Power BI

Una vez implementado el modelo entidad-relación en MySQL, la siguiente etapa consistió en importar esa estructura a Power BI para desarrollar la capa de análisis y visualización del proyecto.

A diferencia de las etapas anteriores, Power BI no se utilizó para transformar ni modelar los datos a nivel relacional. El trabajo en esta herramienta se centró en enriquecer el modelo con elementos propios del análisis y desarrollar un dashboard que facilitara la interpretación de la información.

6.1 Preparación del modelo analítico

La dimensión de fecha no reside en MySQL: se construye en Power BI, de modo que el esquema relacional expone cuatro dimensiones y el modelo semántico cinco. Como primer paso, por tanto, se incorporó una **tabla calendario**, necesaria para habilitar el análisis temporal y las funciones de inteligencia de tiempo. Esta dimensión se relacionó con la tabla de hechos de transacciones, permitiendo analizar la evolución de los indicadores por año, trimestre, mes y fecha.



Posteriormente, se desarrolló una capa de 26 medidas DAX, organizadas en cinco carpetas (Core, Churn and Retention, LTV, RFM y Priorización), para centralizar el cálculo de los principales indicadores utilizados en el dashboard, entre ellos:

- Revenue Total.
- Clientes compradores.
- Total de transacciones.
- Ticket promedio.
- Frecuencia de compra.
- Valor acumulado medio por cliente (LTV Medio).
- Indicadores de evolución temporal.
- Priorización de los clientes en riesgo por facturación histórica.

La clasificación RFM y el indicador de riesgo no se calcularon en DAX: estas variables se habían generado previamente durante la etapa de preparación de datos en Python y se incorporaron al modelo como parte de la dimensión **clientes_rfm**. Las medidas DAX de riesgo y retención se limitan a agregar esa clasificación —contar clientes y calcular proporciones— sin redefinirla, lo que permite mantener una única definición a lo largo de todo el pipeline analítico.

6.2 Desarrollo del dashboard

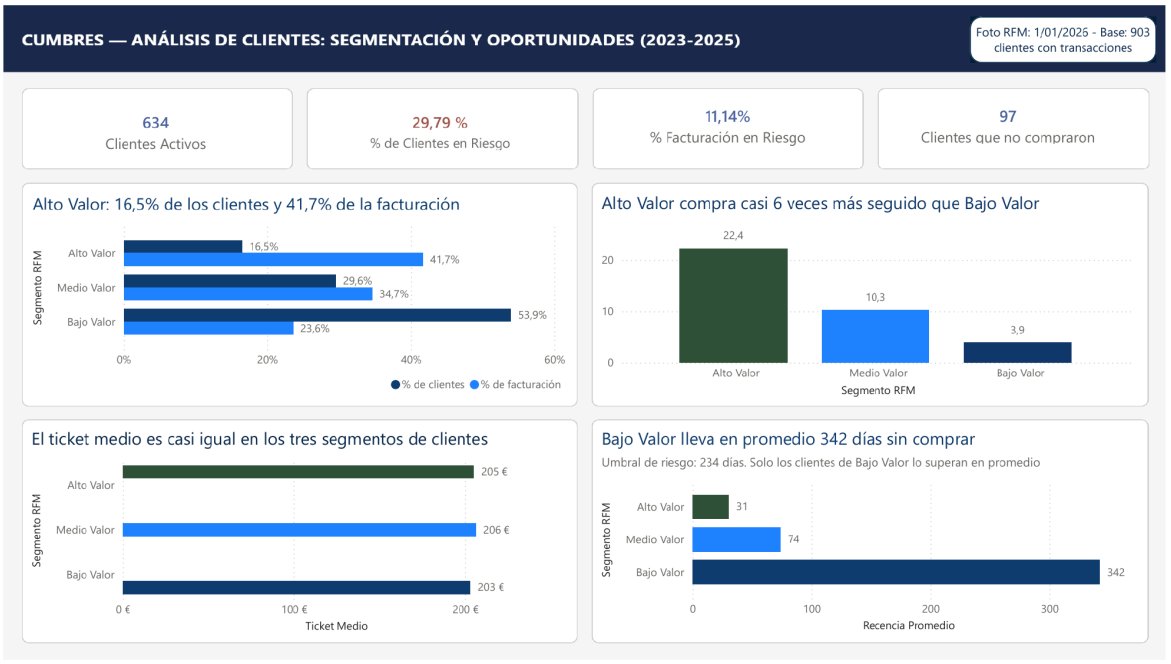
Con el modelo preparado, se diseñó un dashboard ejecutivo compuesto por tres páginas complementarias. Las dos primeras se describen a continuación; la tercera, que traduce el análisis en una lista de contacto, en el apartado 6.3.

La primera página, **Resumen Ejecutivo**, presenta una visión general del desempeño comercial mediante indicadores de facturación, clientes compradores, transacciones, ticket

promedio y evolución temporal, complementados con visualizaciones por tienda y categoría de producto.



La segunda página, **Análisis de Clientes**, profundiza en el comportamiento de los clientes a partir de la segmentación RFM. Compara el peso de cada segmento en clientes y en facturación, muestra que la diferencia de valor la explica la frecuencia de compra y no el ticket, y sitúa la recencia media de cada segmento frente al umbral de 234 días, que solo supera Bajo Valor.

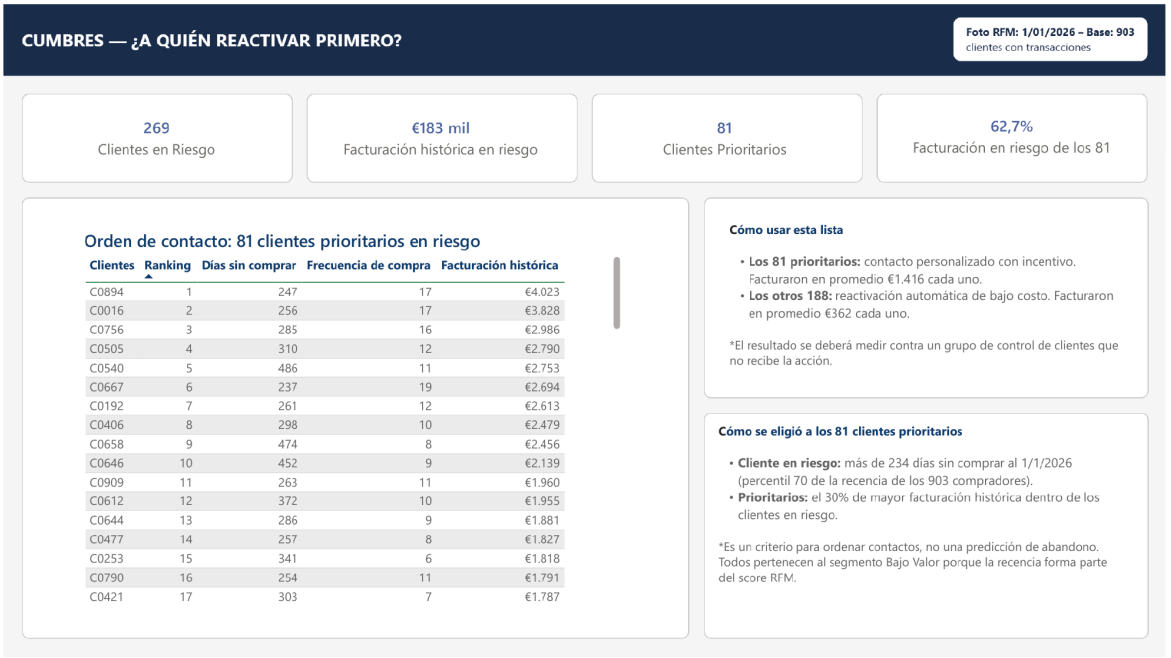


6.3 Página 3: ¿A quién reactivar primero?

La tercera página convierte el diagnóstico de las dos anteriores en una lista de contacto. Parte de los 269 clientes en riesgo —más de 234 días sin comprar al 1/1/2026—, los ordena por su facturación histórica 2023-2025 y destaca a los 81 que forman el 30% superior. Las cuatro tarjetas resumen ese recorrido: 269 clientes en riesgo, €182.755 de facturación histórica en riesgo, 81 clientes prioritarios y el 62,7% de esa facturación concentrado en ellos.

La tabla presenta a los 81 en orden de contacto, con sus días sin comprar, su número de compras y su facturación histórica. Dos bloques de texto completan la lectura. El primero indica cómo usar la lista: contacto personalizado para los 81 prioritarios, que facturaron en promedio €1.416 cada uno, y reactivación automática de bajo costo para los otros 188, con €362 de media; el resultado se mide contra un grupo de control (capítulo 8). El segundo deja el criterio a la vista: es un orden de prioridad, no una predicción de abandono, y los 81 pertenecen al segmento Bajo Valor por construcción (apartado 5.5).

Las medidas de la página pertenecen a la carpeta Priorización (anexo C) y eliminan los filtros sobre clientes_rfm, de modo que las tarjetas no cambian al seleccionar un cliente en la tabla.



6.4 Resultado de la etapa

El resultado de esta etapa es un modelo analítico interactivo que transforma los datos preparados en indicadores para la toma de decisiones comerciales. El dashboard constituye el punto de partida para los Business Insights desarrollados en el capítulo siguiente.

7. Business Insights

Los hallazgos de este capítulo surgen de dos fuentes que se complementan. La primera es la capa de vistas del apartado 5.4: las vistas devuelven el dato ya agregado para cada pregunta analítica, lo que permitió descartar hipótesis y acotar qué cruces contenían señal antes de construir ningún visual. La segunda es el dashboard descrito en el capítulo 6, que aporta lo que una consulta no da: la lectura simultánea de varios indicadores, el filtrado interactivo y la comparación visual entre segmentos y períodos.

Ese recorrido incluye resultados negativos, que se exponen primero. Tres de los cruces explorados no discriminan: la participación de cada segmento en la facturación es prácticamente idéntica en las cinco plazas —Alto Valor oscila entre el 40,5% y el 43,2%—, el mix de categorías no varía de forma relevante entre puntos de venta, y ni la tasa de conversión ni el valor del cliente difieren según el canal de captación. Son diferencias pequeñas, que responden a cómo el generador asigna esos atributos (apartado 9.1). Los seis hallazgos que siguen se apoyan en las dimensiones donde sí hay variación y siguen el recorrido del dashboard: la situación comercial de la página 1 (apartados 7.1 y 7.2), la cartera de clientes y el riesgo de la página 2 (7.3 a 7.5) y la priorización de la página 3 (7.6).

Cada hallazgo presenta la evidencia, su interpretación y el tamaño del problema o la oportunidad; las iniciativas se desarrollan en el capítulo 8. Las cifras corresponden al período 2023-2025 y provienen de las medidas validadas del modelo semántico, reconciliadas contra MySQL según el detalle del anexo B.

7.1 La facturación de 2025 se mantiene estable: la leve caída viene de menos compradores activos

La cartera acumula €1,64M de facturación con 903 clientes compradores y 8.000 transacciones. 2025 cierra un 3,4% por debajo de 2024, y la descomposición de esa variación indica su origen: el número de compradores activos baja de 751 a 730 (−2,8%), la frecuencia por comprador apenas se mueve (de 3,62 a 3,59 compras) y el ticket medio queda plano en torno a €205, prácticamente idéntico entre tiendas (€202-208). La caída no responde a precio ni a una menor frecuencia de quienes siguen comprando, sino a que compraron menos clientes. Su magnitud es modesta: con unas 2.700 transacciones anuales, la diferencia entre ejercicios es de 91 transacciones y, por sí sola, no permite sostener un cambio estructural. Por punto de venta: Valencia crece un 3,8%, mientras Sevilla retrocede un 8,1%, Barcelona un 5,1% y el canal online un 3,5%; con unas 530 transacciones por plaza y año, esas diferencias no se interpretan como desempeño. La variable a seguir es el número de compradores activos (apartado 8.3).

7.2 El liderazgo del canal online depende de una decisión de imputación

Online es el punto de venta de mayor facturación acumulada: €373.872, un 22,8% del total, frente a una media del 19,3% en cada plaza física. Por la misma razón concentra el mayor volumen absoluto de facturación en riesgo, unos €42.700; en proporción, con un 11,41%, es tercero, detrás de Valencia (12,12%) y Madrid (11,90%). Su caída de 2025, un 3,5%, coincide con la de la compañía. La lectura cambia al revisar la limpieza de datos: las 240 transacciones con punto de venta nulo se imputaron a T05 · Web (anexo A). El canal registra 1.831 transacciones; sin las imputadas quedaría en 1.591, dentro del rango de 1.491 a 1.622 de las tiendas físicas, y esas 240 aportan €46.006 de su facturación: sin ellas el canal facturaría €327.866, por debajo de Sevilla (€328.399). El liderazgo del canal, y con él su mayor volumen en riesgo, no puede atribuirse al comportamiento de sus clientes: es en buena medida consecuencia de un criterio de imputación.

7.3 Cuatro de cada diez euros dependen del 16% de los clientes

El segmento Alto Valor reúne 149 clientes —el 16,5% de la base compradora— y aporta el 41,71% de la facturación. En el extremo opuesto, Bajo Valor concentra 487 clientes (53,93% de la base) y explica solo el 23,64% de los ingresos. La diferencia de valor entre ambos extremos es de 5,8 veces: €4.592 de valor acumulado frente a €796. Lo que separa a un cliente de otro no es cuánto gasta por visita, sino cuántas veces vuelve: 22 compras de media en Alto Valor frente a 4 en Bajo Valor, con un ticket casi idéntico. La comparación se sostiene al controlar por el tiempo de exposición de cada cliente, medido desde su primera compra: en términos anuales, Alto Valor factura €1.612 por cliente frente a €358 de Bajo Valor, una brecha de 4,5 veces, algo menor que la del valor acumulado porque los clientes

de Bajo Valor llevan en promedio menos tiempo comprando (2,2 años frente a 2,9). El ticket anualizado sigue siendo el mismo en los tres segmentos (€203-206), de modo que la diferencia es íntegramente de frecuencia.

7.4 El universo en riesgo es amplio en clientes y acotado en facturación

El 29,79% de los compradores (269 de 903) lleva más de 234 días —casi ocho meses— sin comprar y figura en riesgo. Leído en solitario, el número parece una alarma; leído en euros, cambia de signo: esos clientes explican el 11,14% de la facturación de los tres años y solo el 4,1% de la de 2025 (€22.034 de €539.987), porque por definición llevan meses sin comprar. El riesgo se concentra íntegramente en la base de menor valor —el 55,24% del segmento Bajo Valor está en riesgo, frente al 0% de Alto y Medio Valor—, un reparto que responde al diseño de la segmentación (apartado 5.5). La página 2 del dashboard lo muestra con la recencia media: 342 días en Bajo Valor, el único segmento por encima del umbral, frente a 31 y 74 días en Alto y Medio Valor. Por plaza, el peso de esos clientes en la facturación va del 8,99% en Barcelona al 12,12% en Valencia; como en el apartado 7.1, no se interpreta como diferencia de capacidad de retención.

7.5 Hay 97 clientes ya captados que nunca llegaron a comprar

De los 1.000 clientes registrados en el CRM, 97 —el 9,7%— no tienen ninguna compra asociada. Son registros ya captados que nunca completaron la primera transacción. A valor de ticket medio, convertir a un tercio de ese grupo —un escenario de referencia, no una meta— aportaría del orden de €6.600 de facturación incremental sin inversión adicional en captación. La cifra equivale al 0,4% de la facturación del período y se calcula antes de descontar el incentivo: la oportunidad es de ciclo corto, pero de alcance acotado.

7.6 81 clientes concentran casi dos tercios del valor en riesgo

La página 3 del dashboard ordena a los 269 clientes en riesgo por su facturación histórica. El 30% superior —81 clientes— reúne €114.670, el 62,7% de los €182.755 de facturación histórica en riesgo: facturaron en promedio €1.416 cada uno, frente a €362 de los otros 188, casi cuatro veces más. Esa concentración convierte una campaña masiva sobre 269 clientes en una acción dirigida a 81. Dos límites acotan la lectura: la cifra es facturación pasada y no un importe recuperable, y que los 81 pertenezcan al segmento Bajo Valor es una consecuencia del diseño de la segmentación, no un rasgo comercial (apartado 5.5). La iniciativa correspondiente se desarrolla en el apartado 8.1.

8. Recomendaciones

Cada iniciativa se desprende de un hallazgo del capítulo 7 y sigue la secuencia evidencia → iniciativa → KPI. Se presentan como hipótesis de acción a validar: el dataset permite dimensionar la oportunidad, no demostrar que una acción funcione, y las cifras son facturación observada, no margen ni retorno (apartado 9.1). Los incentivos de precio se

limitan a dos poblaciones —clientes en riesgo y registros sin compra—, donde no hay ticket que proteger o la alternativa es no comprar.

8.1 Líneas de acción por segmento RFM

Alto Valor — 149 clientes · 16,5% de la base compradora · 41,71% de la facturación

Evidencia: €684.150 de facturación acumulada; ningún cliente del segmento figura hoy en riesgo, por el diseño del segmento (apartado 5.5).

- **Iniciativa (hipótesis a validar):** programa de fidelización sin descuentos de precio (acceso prioritario, envío gratuito, atención preferente) y gestión de cuenta a nivel de cartera, con alerta de inactividad antes de alcanzar el umbral de 234 días. Cada cliente de Alto Valor factura en promedio €1.612 al año (€4.592 acumulados en 2023-2025).
- **Cross-sell por categoría (hipótesis):** requiere el cruce entre segmento y composición de canasta, que el modelo no incorpora (apartado 9.2).

KPI: tasa de retorno a 12 meses de la cohorte Alto Valor (apartado 8.3).

Medio Valor — 267 clientes · 29,57% de la base compradora · 34,66% de la facturación

Evidencia: compran unas 3,8 veces al año frente a 7,9 de Alto Valor, con un ticket similar; la distancia equivale a unos €825 anuales por cliente (€1.612 frente a €787).

- **Iniciativa (hipótesis a validar):** incentivo escalonado por número de compras y recordatorio de recompra sin descuento antes de alcanzar el umbral de 234 días: el cliente sigue activo y un descuento subsidiaría compras que ocurrirían igual.
- **Bundle de categorías (hipótesis):** el ticket es homogéneo entre segmentos (~€205), por lo que la palanca de ticket no está acreditada; se contrasta con datos productivos.

KPI: compras por cliente de la cohorte Medio Valor (apartado 8.3).

Bajo Valor — 487 clientes · 53,93% de la base compradora · 23,64% de la facturación

Evidencia: el segmento concentra todo el universo en riesgo: 269 clientes y €182.755 de facturación 2023-2025, de los cuales €114.670 (62,7%) corresponden a los 81 clientes del 30% superior en facturación histórica (deciles 1 a 3 de v_retencion_prioridad; página 3 del dashboard).

- **Iniciativa (hipótesis a validar):** reactivación con incentivo empezando por esos 81 clientes y reactivación automatizada de bajo costo para los otros 188, en lugar de una campaña masiva sobre los 269, cuyo costo difícilmente se recupera con una facturación histórica de €679 por cliente. El efecto se mide contra un grupo de control aleatorio de clientes.

KPI: tasa de retorno de la cohorte en riesgo y facturación anual por cliente de la cohorte Bajo Valor (apartado 8.3).

Sin Transacciones — 97 clientes · 9,7% de la base registrada de 1.000 · 0% de la facturación

Evidencia: registros captados que nunca completaron una compra; la oportunidad, de ciclo corto y alcance acotado, se dimensiona en el apartado 7.5.

- **Investigación de causas (paso previo):** analizar bloqueos de conversión (calidad del email, experiencia de usuario, disponibilidad de producto). Como fecha_alta no es confiable, no puede distinguirse entre leads fríos y registros recientes (apartado 4.2).
- **Campaña de primera compra (hipótesis a validar):** email, SMS y retargeting digital con incentivo de primera compra (20% de descuento), grupo donde se admite incentivo de precio porque no hay ticket previo que erosionar. Los 97 se reparten de forma proporcional entre los cuatro canales de captación, por lo que la campaña no admite priorización por origen.

KPI: conversión de los registros sin transacciones (apartado 8.3).

8.2 Acciones por tienda y canal

Como las plazas no se diferencian de forma interpretable (apartados 7.1 y 9.1), el cuadro no asigna estrategias por tienda sino criterios de seguimiento. La única particularidad corresponde al canal online: verificar su facturación imputada.

Tienda	Acción prioritaria	Responsabilidad
Sevilla	Seguimiento: confirmar en 2026 si la caída del 8,1% persiste antes de asignar recursos específicos	Gerente de tienda · Dirección comercial
Madrid	Sin acción diferenciada: recibe el plan de retención por cartera como el resto de plazas. El efecto se mide con un grupo de control aleatorio de clientes, no con una tienda de control	Gerente de tienda
Barcelona	Seguimiento de la caída del 5,1% con el mismo criterio que Sevilla	Gerente de tienda · Dirección comercial
Valencia	Seguimiento: el crecimiento del 3,8% no se trata como estrategia replicable mientras no se confirme con datos productivos	Dirección comercial
Online	Verificar el origen de las 240 transacciones imputadas a T05 antes de comparar su facturación con la de las plazas físicas (apartado 7.2). El piloto de retención, digital y dirigido a clientes, no depende de esta verificación	Responsable de e-commerce

8.3 KPIs de seguimiento del plan

Métrica	Objetivo
Tasa de retorno · cohorte Alto Valor	Retorno a 12 meses, con seguimiento trimestral
Compradores activos por año	Seguimiento trimestral sobre la base de 730 compradores de 2025; se trata como tendencia solo si cae dos ejercicios consecutivos (apartado 7.1)
Tasa de retorno · cohorte en riesgo	Retorno a 12 meses superior al de un grupo de control aleatorio del 10%.
Compras por cliente · cohorte Medio Valor	Superior a la del grupo de control (referencia 2023-2025: 3,8 compras al año)
Facturación anual por cliente · cohorte Bajo Valor	Superior a la del grupo de control (referencia 2023-2025: €358 por cliente y año)
Conversión de Sin Transacciones	Superior a la del grupo de control
Efecto incremental del plan	Facturación por cliente superior en el grupo tratado frente al grupo de control, medida cada trimestre

Las metas se expresan contra un grupo de control aleatorio y no como porcentajes fijos, porque el proyecto no tiene una referencia que justifique una cifra concreta: es el piloto el que debe establecerla. Los indicadores se revisan cada trimestre sobre ventanas de 12 meses, y las métricas por segmento se miden sobre cohortes fijadas en la fecha de referencia y no sobre la composición vigente: un cliente reactivado sube de segmento y haría que el éxito de la acción empeorara el indicador.

9. Limitaciones y consideraciones a futuro

9.1 Limitaciones del proyecto

Las conclusiones de los capítulos 7 y 8 deben leerse dentro de estos límites.

1. Dataset sintético: algunas regularidades responden al generador y no al comportamiento real de compra, en particular la homogeneidad del ticket entre segmentos (~€205) y la asignación del punto de venta y del canal de captación con independencia del comportamiento del cliente. Por eso la conclusión del apartado 7.3 (el valor lo construye la frecuencia) debe revalidarse con datos productivos, y las diferencias entre plazas no se interpretan como desempeño.

2. Inconsistencias de fecha_alta: es inconsistente con las transacciones en 739 de 903 compradores; no se usa para antigüedad, cohortes ni tiempo desde el alta, y para los 97 registros sin compra impide distinguir leads fríos de registros recientes. No afecta el cálculo de recencia (apartado 4.2).

3. Imputación de store_id nulo: las 240 transacciones sin punto de venta se imputaron a T05 · Web. Es una convención razonable pero no neutral: explica la mayor parte de la ventaja del canal online en facturación (apartado 7.2).

4. Falta de variables económicas: sin costos, márgenes, costo de adquisición ni elasticidad precio, las cifras del capítulo 8 dimensionan sobre facturación observada: acotan el orden de magnitud de cada oportunidad, no su rentabilidad.

5. RFM y riesgo basados en un snapshot: la segmentación es una fotografía al 1/1/2026 y no captura trayectorias entre segmentos. La facturación por segmento y ejercicio (v_contribucion_segmento_anio) aplica la segmentación actual de forma retroactiva: indica cuánto facturó cada año quien hoy es Alto Valor, no quién lo era entonces.

6. Umbral no calibrado: el percentil 70 es un criterio operativo. No se contrastó qué corte maximiza la separación entre grupos ni se ajustó al ciclo de recompra o a la estacionalidad reales del negocio: está justificado, no optimizado.

7. Sin variable observada de abandono: el dataset no registra bajas; el indicador mide inactividad elevada y no abandono consumado.

8. Análisis cliente-tienda y cliente-producto limitado: un mismo comprador opera en 3,46 plazas de media (3.124 vínculos cliente-tienda para 903 compradores), por lo que el modelo no responde cuánto vale un cliente para una plaza y el desglose por tienda se limita a facturación. Tampoco se cruzó la segmentación con la categoría de producto.

9. Sin cohortes ni evolución temporal: no hay análisis de cohortes ni de migración entre segmentos, que sería la vía para saber si el volumen en riesgo del canal online es deterioro real o rotación normal de cartera.

10. Escalabilidad: con 1.000 clientes y 8.000 transacciones el pipeline no enfrenta restricciones de rendimiento; su comportamiento con volúmenes productivos no se demuestra (apartado 9.2).

9.2 Próximas fases del proyecto

El proyecto cubre la fase descriptiva y la diagnóstica de la analítica de clientes y una capa prescriptiva basada en reglas; la fase predictiva queda fuera del alcance. Las líneas que siguen consolidan esa base y se ordenan por dependencia: las primeras habilitan a las siguientes.

Granularidad cliente-punto de venta: recalcular las métricas RFM con clave compuesta cliente-tienda, de modo que el modelo pueda responder por actividad y valor en cada plaza. Sobre este dataset no rendiría (apartado 9.1); aplica a datos productivos, donde su primer entregable no es el recálculo sino la comprobación de si corresponde hacerlo.

Calibración del umbral de riesgo: contrastar qué punto de corte maximiza la separación entre clientes activos y en riesgo, y ajustarlo al ciclo de recompra y a la estacionalidad de cada categoría, en lugar de fijarlo por percentil. Es el paso previo a automatizar cualquier alerta basada en él (apartado 9.1).

Análisis de cohortes: agrupar clientes por fecha de primera compra —no por fecha de alta, que no es confiable (apartado 4.2)— y seguir su comportamiento a lo largo del tiempo. Es la vía para determinar, una vez verificada la imputación del punto de venta, si el volumen de facturación en riesgo del canal online responde a un deterioro real o a la rotación normal de cartera, distinción que hoy el modelo no permite establecer.

Segmento y composición de canasta: cruzar la segmentación RFM con la categoría de producto para saber si los segmentos difieren en lo que compran. Es la información que falta para dimensionar las acciones de cross-sell y bundle del capítulo 8, que hoy quedan planteadas como hipótesis.

Segmentación dinámica: transición del RFM estático (snapshot) a ventanas móviles, con recálculo automático trimestral para capturar los cambios de comportamiento de la base.

Industrialización: con datos productivos, automatizar la ingesta desde los sistemas de origen (ERP y CRM), programar el recálculo de la segmentación y conectar las listas de

clientes priorizados con la herramienta de marketing, de modo que las alertas de inactividad y el seguimiento contra el grupo de control del capítulo 8 funcionen sin intervención manual.

10. Anexo

A. Diccionario de datos

`clientes` — tabla de dimensión · 1.000 registros

Campo	Tipo	Clave	Descripción
customer_id	VARCHAR	PK	Identificador único del cliente. Clave de unión con transacciones y clientes_rfm.
nombre	VARCHAR	—	Nombre del cliente (PII). VARCHAR(30).
email	VARCHAR	—	Correo electrónico (PII). 40 nulos conservados, sin patrón sistémico.
ciudad	VARCHAR	—	Ciudad del cliente. 50 nulos conservados.
canal_adquisicion	VARCHAR	—	Canal por el que se captó al cliente. Base del análisis de conversión.
fecha_alta	DATE	—	Fecha de registro del cliente en el CRM. Inconsistente con las transacciones en 739 de 903 compradores (apartado 4.2); no se utiliza analíticamente.

`productos` — tabla de dimensión · 48 registros

Campo	Tipo	Clave	Descripción
product_id	VARCHAR	PK	Identificador único del producto.
nombre	VARCHAR	—	Nombre comercial del producto.
categoria	VARCHAR	—	Línea de producto: Montaña y Trekking, Running y Trail, Ciclismo o Pádel.
precio_base	DECIMAL(10,2)	—	Precio de referencia del producto.

`tiendas` — tabla de dimensión · 5 registros

Campo	Tipo	Clave	Descripción
store_id	VARCHAR	PK	Identificador del punto de venta (T01–T05).
nombre	VARCHAR	—	Nombre del punto de venta.
ciudad	VARCHAR	—	Madrid (T01), Barcelona (T02), Valencia (T03), Sevilla (T04). T05 = canal Web de alcance nacional.

`transacciones` — tabla de hechos · 8.000 registros

Campo	Tipo	Clave	Descripción
transaction_id	VARCHAR	PK	Identificador único de la transacción.
customer_id	VARCHAR	FK	Referencia a clientes.customer_id.
product_id	VARCHAR	FK	Referencia a productos.product_id.
store_id	VARCHAR	FK	Referencia a tiendas.store_id. 240 nulos imputados a T05 · Web.
fecha	DATE	—	Fecha de la transacción. Eje temporal del análisis.
cantidad	INT	—	Unidades de la transacción.
importe	DECIMAL(10,2)	—	Importe neto. Admite negativos (80 devoluciones). Corregido por el factor ×8 en 146 registros.

clientes_rfm — tabla derivada analítica (snapshot) · 1.000 registros

Campo	Tipo	Clave	Descripción
customer_id	VARCHAR	PK·FK	Referencia a clientes.customer_id. Relación 1:1.
recencia	INT	—	Días desde la última compra. 999 = placeholder para Sin Transacciones.
frecuencia	INT	—	Número de transacciones del cliente, devoluciones incluidas.
monetario	DECIMAL(10,2)	—	Valor monetario acumulado del cliente (LTV).
segmento_rfm	VARCHAR	—	Alto Valor · Medio Valor · Bajo Valor · Sin Transacciones.
churn_riesgo	TINYINT	—	1 = en riesgo (recencia > 234 días, percentil 70 y recencia <> 999); 0 = activo. Los 97 clientes sin transacciones reciben 0: son leads no convertidos, no clientes fugados.
fecha_calculo	DATE	—	Fecha de referencia del snapshot: 2026-01-01, fijada como max(transacciones.fecha) + 1 día. Constante para los 1.000 registros.

Los tipos y longitudes recogidos en las tablas anteriores se corresponden con la DDL implementada en MySQL. La clave `customer_id` mantiene el mismo nombre físico en `clientes` y en `clientes_rfm`, de modo que la relación 1:1 se resuelve en Power BI sin ambigüedad.

B. Capa SQL: consultas, vistas y reconciliación

Este anexo documenta el trabajo realizado sobre MySQL en dos bloques con propósitos distintos: las vistas analíticas que persisten la lógica de negocio y el conjunto de consultas que reconcilia cada indicador del modelo semántico contra la fuente relacional.

B.1 Capa de vistas analíticas

La capa está descrita en el apartado 5.4, donde figura la correspondencia entre cada pregunta analítica y la vista que la resuelve. Este bloque recoge las decisiones de construcción que no se leen en el código. Dos son transversales a toda la capa: el porcentaje de participación se calcula con funciones de ventana en lugar de subconsultas, porque MySQL las restringe dentro de las definiciones de vista; y todos los cruces con las dimensiones se resuelven con LEFT JOIN, de modo que una clave foránea huérfana se manifieste como valor nulo en lugar de hacer desaparecer filas en silencio y falsear la facturación sin aviso.

Decisiones de construcción. El script con las ocho vistas y sus comentarios de diseño reside en views_customer_analytics.sql.

v_hechos_transacciones. Vista plana para exploración y validación cruzada. El script advierte no conectarla a Power BI: aplanar el esquema estrella destruiría el modelo dimensional del apartado 5.1.

v_rfm_cliente. Una fila por cliente registrado (1.000, no los 903 compradores). Incorpora una columna que separa al cliente sin historial —recencia 999, un placeholder y no una antigüedad— del comprador real, para que no entre en ningún cálculo de riesgo.

v_contribucion_segmento_anio. Mide la contribución real sobre la tabla de hechos por ejercicio, a diferencia de v_distribucion_cartera, que mide el valor acumulado del snapshot. El segmento se calcula a la fecha de referencia y se aplica retroactivamente a 2023-2025: dice cuánto facturó en 2023 quien hoy es Alto Valor, no quién era Alto Valor en 2023 (limitación en el apartado 9.1).

v_desempeno_tienda_segmento, retirada. Cruzaba el punto de venta con el segmento RFM y contaba clientes por tienda: las cinco filas sumaban 3.124 vínculos cliente-tienda y no los 903 compradores (apartado 9.1). Además el cruce no aportaba señal: Alto Valor pesa entre 40,52% y 43,18% de la facturación de cada tienda. Criterio resultante: el comportamiento del cliente se analiza a nivel de cartera y el desglose por punto de venta se apoya solo en facturación.

Validación de la capa. El mismo archivo incluye diez controles que se ejecutan tras cada regeneración de clientes_rfm: integridad referencial (10.1), coherencia del snapshot contra la tabla de hechos (10.2), anclaje de la fecha de referencia (10.3), umbral de 234 días efectivamente persistido (10.4), distribución de recencia (10.5), cifras de cabecera (10.6), las dos lecturas del riesgo sobre 903 y sobre 1.000 (10.7), inventario de vistas (10.8), lectura Web frente a física (10.9) y coherencia contra el dashboard (10.10). Los controles 10.3 y 10.9 son los que se citan en el cuerpo del informe.

B.2 Reconciliación MySQL y Power BI

Cada medida DAX del anexo C se recalculó de forma independiente contra la base relacional y se comparó con el valor que devuelve el modelo semántico, verificando su coincidencia exacta. Las consultas están en customer_analytics_reconciliacion_mysql_powerbi.sql, ejecutable contra la base del proyecto; aquí se consigna qué medidas valida cada una y el resultado esperado.

Las dos últimas consultas cumplen una función distinta: B.2.9 documenta la posición del umbral en la distribución de recencia y B.2.10 documenta con datos la limitación de granularidad declarada en el apartado 9.1.

B.2.1 Indicadores comerciales globales. Medidas: Revenue Total, Total Transacciones, Total Clientes, Ticket Medio, Frecuencia Compra.

Esperado: 1640308.39 | 8000 | 903 | 205.04 | 8.86

B.2.2 Serie anual y crecimiento interanual. Medida: Crecimiento 2025 vs 2024.

Esperado: 2023 541437.75 / 2661 / 743 - 2024 558883.32 / 2715 / 751 - 2025 539987.32 / 2624 / 730. Crecimiento: -3.38

B.2.3 Distribución por segmento RFM. Medidas: Clientes Segmento, % Clientes Segmento, LTV Medio, Recencia Promedio, Frecuencia Promedio.

Esperado: Alto 149 / 16.50 / 4591.61 / 30.6 / 22.38 - Medio 267 / 29.57 / 2129.09 / 74.1 / 10.32 - Bajo 487 / 53.93 / 796.08 / 342.2 / 3.92

B.2.4 Participación de cada segmento en la facturación. Medida: % Revenue Segmento. Se calcula desde la tabla de hechos y no desde clientes_rfm.monetario, para verificar que ambas fuentes coinciden.

Esperado: Alto 684149.79 / 41.71 - Medio 568467.12 / 34.66 - Bajo 387691.48 / 23.64

B.2.5 Riesgo y retención. Medidas: % Clientes en Riesgo, % Retención, Clientes Activos, Clientes Inactivos (En Riesgo), Usuarios Sin Transacciones.

Esperado: 634 | 269 | 97 | 29.79 | 70.21

B.2.6 Riesgo por segmento. Verifica la distribución 0% / 0% / 55,24% del apartado 7.4.

Esperado: Alto 149 / 0 / 0.00 - Medio 267 / 0 / 0.00 - Bajo 487 / 269 / 55.24

B.2.7 Facturación en riesgo. Medida: % Revenue en Riesgo. Es la métrica que sostiene el hallazgo central del apartado 7.4: universo en riesgo amplio en clientes y acotado en facturación.

Esperado: 182754.98 | 1640308.39 | 11.14

B.2.8 Desempeño por tienda y canal. Único desglose por plaza admitido: métricas de facturación, que se atribuyen a nivel de transacción y reparten sin solapamiento.

Esperado: Web 373871.91 / 204.19 / -3.50 / 11.41 - Sevilla 328398.66 / 202.47 / -8.09 / 11.26 - Barcelona 314836.91 / 205.64 / -5.09 / 8.99 - Madrid 313477.52 / 205.56 / -3.39 / 11.90 - Valencia 309723.39 / 207.73 / +3.83 / 12.12

B.2.9 Posición del umbral de riesgo. Verifica la posición del umbral de 234 días dentro de la distribución de recencia de la base compradora.

Esperado: 903 | 1 | 1096 | 211.5 | 242.3 | 70.21. El umbral de 234 días deja al 70,21% de los compradores por debajo: es el percentil 70 exacto de la distribución, calculado en Python.

B.2.10 No aditividad de los conteos de cliente por tienda. Evidencia de la limitación declarada en el apartado 9.1: clientes_rfm tiene granularidad cliente, no cliente-tienda.

Esperado: 3124 | 903 | 3.46. Un mismo cliente opera en 3,46 plazas en promedio, de modo que cualquier conteo de clientes desglosado por tienda lo registraría varias veces.

C. Índice de Medidas DAX

Modelo semántico Power BI · Cumbres Outdoor & Deportes. Validado contra el modelo en ejecución. Período 2023-2025. Fecha de referencia RFM: 2026-01-01.

El modelo semántico expone 26 medidas organizadas en cinco carpetas de visualización: Core, Churn and Retention, LTV, RFM y Priorización. El código DAX completo se publica en la carpeta tmdl_export del repositorio; en este anexo se transcribe solo el de las nueve medidas cuya construcción incorpora una decisión de diseño —neutralización de contexto, TREATAS, KEEPFILTERS o ALL—, y para el resto se consigna la validación y su lectura.

Cada validación consignada a continuación fue verificada contra el modelo en ejecución y es reproducible mediante las consultas del apartado B.2, que calculan el mismo indicador directamente sobre MySQL. La segmentación RFM y el umbral de riesgo (234 días, percentil 70 de la recencia) se calculan una única vez en Python sobre los 903 clientes con historial transaccional y se persisten en MySQL como snapshot estático: ni SQL ni DAX los recalculan.

C.1 CORE · Indicadores comerciales

Dinámicas. Responden a los slicers de año y tienda (página 1).

1. Revenue Total

Validación: 1.640.308,39 € en el período. Serie anual: 2023 541.437,75 € · 2024 558.883,32 € · 2025 539.987,32 €.

Formato: €#,##0.00

Incluye las 80 devoluciones (importe negativo) como parte del ciclo de venta legítimo, y refleja la corrección del factor por 8 sobre 146 registros.

2. Total Clientes

Validación: 903 clientes con al menos una transacción. Por año: 743 en 2023, 751 en 2024, 730 en 2025.

Clientes únicos con historial transaccional en el contexto de filtro activo. Responde a filtros de año y tienda, y por tanto devuelve compradores por plaza: la lectura de cada plaza es correcta, pero la suma de las cinco no es la de la cartera (apartado 9.1).

3. Total Transacciones

Validación: 8.000 registros.

4. Ticket Medio

Validación: 205,04 €. Rango por plaza: 202,47 € en Sevilla a 207,73 € en Valencia.

Formato: €#,0.00

Métrica de comparación entre puntos de venta: normaliza las diferencias de escala entre plazas. Es neta de devoluciones; calculado solo sobre ventas, el ticket es de €209,13. Su homogeneidad es el fundamento del apartado 7.1.

5. Frecuencia Compra

Validación: 8,86 transacciones por cliente comprador. Cuenta las 80 devoluciones como transacciones; sin ellas, la frecuencia por segmento apenas cambia (Alto Valor 22,2 frente a 3,9 de Bajo Valor) y la brecha se mantiene en 5,7 veces.

6. Crecimiento 2025 vs 2024

```
VAR Revenue2025 =
    CALCULATE(
```

```
        [Revenue Total],
        REMOVEFILTERS(Calendario[Año]),
        Calendario[Año] = 2025
    )
VAR Revenue2024 =
    CALCULATE(
        [Revenue Total],
        REMOVEFILTERS(Calendario[Año]),
        Calendario[Año] = 2024
    )
RETURN
DIVIDE(Revenue2025 - Revenue2024, Revenue2024, 0)
```

Validación: -3,38% (539.987,32 € frente a 558.883,32 €). Por plaza: Valencia +3,83% · Madrid -3,39% · Web -3,50% · Barcelona -5,09% · Sevilla -8,09%.

Fija los años explícitamente con REMOVEFILTERS para que la comparación se sostenga aunque haya un slicer de año activo. Responde al slicer de tienda, que es lo que habilita el desglose anterior.

C.2 CHURN AND RETENTION · Retención de clientes

Snapshot RFM sobre la base de 903 compradores (página 2).

7. % Clientes en Riesgo

```
DIVIDE(
    CALCULATE(
        DISTINCTCOUNT(clientes_rfm[customer_id]),
        clientes_rfm[churn_riesgo] = 1,
        clientes_rfm[recencia] <> 999
    ),
    CALCULATE(
        DISTINCTCOUNT(clientes_rfm[customer_id]),
        clientes_rfm[recencia] <> 999
    ),
    0
)
```

Validación: 29,79% (269 clientes en riesgo sobre 903 compradores).

Formato: 0.00%

Calculado sobre clientes con historial transaccional real, excluyendo a los 97 no convertidos (recencia = 999). Mezclar clientes en riesgo con leads no calificados produciría una tasa que no orienta ninguna decisión: las dos poblaciones requieren acciones comerciales opuestas.

8. % Retención

```
DIVIDE(
    [Clientes Activos],
    [Clientes Activos] + [Clientes Inactivos (En Riesgo)],
    0
)
```

Validación: 70,21% (634 activos sobre 903). Complemento exacto de % Clientes en Riesgo.

Verificada estable en los tres ejercicios y en las cinco plazas tras la neutralización de contexto aplicada a las medidas 9 y 10.

9. Clientes Activos

```
VAR ClientesEnContexto =
    CALCULATETABLE(
        VALUES(transacciones[customer_id]),
        REMOVEFILTERS(Calendario),
        REMOVEFILTERS(tiendas)
    )
RETURN
CALCULATE(
    COUNTROWS(clientes_rfm),
    KEEPFILTERS(clientes_rfm[customer_id] IN ClientesEnContexto),
    clientes_rfm[churn_riesgo] = 0,
    clientes_rfm[recencia] <> 999
)
```

Validación: 634 clientes activos (churn_riesgo = 0, recencia de hasta 234 días). Por segmento: Alto Valor 149 · Medio Valor 267 · Bajo Valor 218.

La doble neutralización de contexto responde a que la recencia se mide una sola vez contra la fecha de referencia (ver Nota arquitectónica).

10. Clientes Inactivos (En Riesgo)

```
VAR ClientesEnContexto =
    CALCULATETABLE(
        VALUES(transacciones[customer_id]),
        REMOVEFILTERS(Calendario),
        REMOVEFILTERS(tiendas)
    )
RETURN
CALCULATE(
    COUNTROWS(clientes_rfm),
    KEEPFILTERS(clientes_rfm[customer_id] IN ClientesEnContexto),
    clientes_rfm[churn_riesgo] = 1,
    clientes_rfm[recencia] <> 999
)
```

Validación: 269 clientes en riesgo (churn_riesgo = 1, recencia mayor a 234 días), excluidos los sin transacciones. Por segmento: Alto Valor 0 · Medio Valor 0 · Bajo Valor 269, el 55,24% de ese segmento.

11. Usuarios Sin Transacciones

Validación: 97 clientes, el 9,7% de la base registrada de 1.000.

Es la única medida del modelo cuyo denominador natural son los 1.000 registros del CRM y no los 903 compradores. Cualquier mención de este 9,7% debe declarar esa base.

12. % Revenue en Riesgo

```
VAR ClientesRiesgo =
    CALCULATETABLE(
        VALUES(clientes_rfm[customer_id]),
        clientes_rfm[churn_riesgo] = 1
```

```
    )
VAR RevRiesgo =
    CALCULATE(
        [Revenue Total],
        REMOVEFILTERS(Calendario),
        TREATAS(ClientesRiesgo, transacciones[customer_id])
    )
VAR RevTotal =
    CALCULATE([Revenue Total], REMOVEFILTERS(Calendario))
RETURN
DIVIDE(RevRiesgo, RevTotal)
```

Validación: 11,14% de la facturación, 182.754,98 €. Por plaza: Barcelona 8,99% · Sevilla 11,26% · Web 11,41% · Madrid 11,90% · Valencia 12,12%. Dentro de Bajo Valor: 47,14% de la facturación del segmento.

Formato: 0.00%

Versión ponderada por valor de la proporción de clientes en riesgo: mide la facturación histórica 2023-2025 de los clientes hoy en riesgo, no facturación futura comprometida. Es la medida que sostiene el hallazgo central del apartado 7.4: el universo en riesgo es amplio en clientes y acotado en facturación. Usa TREATAS para trasladar la lista de clientes en riesgo al filtro de la tabla de hechos.

C.3 LTV · Valor de vida útil

Snapshot RFM. Inmune a slicers temporales y de tienda. No se muestra en el dashboard: se usa en el informe como valor acumulado por segmento (apartado 7.3).

13. LTV Medio

```
CALCULATE(
    AVERAGEX(
        VALUES(clientes_rfm[customer_id]),
        CALCULATE(
            SUM(transacciones[importe]),
            REMOVEFILTERS(Calendario)
        )
    ),
    REMOVEFILTERS(tiendas)
)
```

Validación: 1.816,51 € global. Alto Valor 4.591,61 € · Medio Valor 2.129,09 € · Bajo Valor 796,08 €. Brecha Alto/Bajo: 5,8 veces.

Formato: #,0.00 €

Doble neutralización de contexto por dos motivos distintos. REMOVEFILTERS(Calendario) responde a que el LTV es un valor acumulado de vida: segmentarlo por año produciría un "LTV de 2023" que suma únicamente las transacciones de ese ejercicio. REMOVEFILTERS(tiendas) responde a la granularidad de la tabla: clientes_rfm tiene una fila por cliente y no por cliente y plaza, de modo que un LTV por tienda contaría al mismo comprador en varias cajas. Por convención del modelo la medida se denomina LTV, pero mide el valor histórico acumulado entre 2023 y 2025, no un valor de vida proyectado.

El desglose por segmento sí es válido y se conserva, porque cada cliente pertenece a un único segmento RFM.

RFM · Segmentación de valor

Snapshot estático. Distribución por segmento (página 2).

14. Clientes Segmento

Validación: Alto Valor 149 · Medio Valor 267 · Bajo Valor 487. Total 903.

Excluye por diseño a los 97 no convertidos, que devuelven vacío en esta medida y se cuantifican mediante la medida 11. Esa exclusión es la que fija en 903 el denominador de la medida 15.

15. % Clientes Segmento

```
DIVIDE(
    [Clientes Segmento],
    CALCULATE(
        [Clientes Segmento],
        ALL(clientes_rfm[segmento_rfm], clientes_rfm[orden_segmento])
    )
)
```

Validación: Alto Valor 16,50% · Medio Valor 29,57% · Bajo Valor 53,93%.

ALL() sobre el segmento calcula el denominador total (903 compradores, porque la medida 14 excluye a los no convertidos). Los tres porcentajes suman 100%. Incluye orden_segmento, la columna creada en Power Query que ordena los segmentos de mayor a menor valor en los visuales: Power BI la agrega a toda consulta que usa segmento_rfm, y sin ella cada segmento devolvería el 100%. La medida 16 aplica el mismo criterio.

16. % Revenue Segmento

```
VAR RevSegmento =
    CALCULATE([Revenue Total], REMOVEFILTERS(Calendario))
VAR RevTotalSegmentos =
    CALCULATE(
        [Revenue Total],
        REMOVEFILTERS(Calendario),
        REMOVEFILTERS(clientes_rfm[segmento_rfm], clientes_rfm[orden_segmento])
    )
RETURN
DIVIDE(RevSegmento, RevTotalSegmentos)
```

Validación: Alto Valor 41,71% (684.149,79 €) · Medio Valor 34,66% (568.467,12 €) · Bajo Valor 23,64% (387.691,48 €). Por plaza, la participación de Alto Valor oscila entre 40,52% en Madrid y 43,18% en Barcelona.

Formato: 0.0%

Contrapone la participación en facturación a la participación en clientes de la medida 15, y es la comparación que sostiene el apartado 7.3.

17. Recencia Promedio

Validación: Alto Valor 31 días · Medio Valor 74 · Bajo Valor 342. Global 211,5.

Excluye el placeholder recencia = 999 para no distorsionar el promedio.

18. Frecuencia Promedio

Validación: Alto Valor 22,4 compras · Medio Valor 10,3 · Bajo Valor 3,9.

Reconciliación: 149 por 22,38 más 267 por 10,32 más 487 por 3,92 da 7.999, coherente con las 8.000 transacciones del modelo.

Confirma el hallazgo del apartado 7.3: la diferenciación RFM está impulsada por la frecuencia y no por el ticket, que permanece homogéneo en torno a 205 € entre segmentos. La atribución es dominante, no exclusiva: los rangos de frecuencia se solapan entre segmentos (Bajo 1 a 20, Medio 5 a 33, Alto desde 11) porque la clasificación responde a un score compuesto.

PRIORIZACIÓN · Clientes a reactivar

Snapshot fijo sobre los 269 clientes en riesgo (página 3). Las ocho medidas eliminan los filtros sobre clientes_rfm (REMOVEFILTERS o ALL), de modo que las cifras no cambian al seleccionar un cliente en la tabla. La lista coincide con los deciles 1 a 3 de la vista v_retencion_prioridad.

19. Clientes en Riesgo (Foto)

Validación: 269 clientes. Versión de la medida 10 sin contexto de filtro, para la tarjeta de la página 3.

20. Revenue Histórico en Riesgo

Validación: 182.754,98 € de facturación 2023-2025 de los clientes en riesgo.

21. Clientes Prioritarios

Validación: 81 clientes: el 30% de 269 redondeado (80,7).

22. Ranking Valor en Riesgo

Validación: posiciones 1 a 269 por facturación histórica descendente; vacío para clientes activos y sin transacciones.

23. Es Prioritario

Validación: 1 para 81 clientes. Filtro de la tabla de la página 3 (Es Prioritario = 1).

24. Revenue Clientes Prioritarios

Validación: 114.669,55 €.

25. % Valor en Riesgo en Prioritarios

Validación: 62,7% (114.669,55 € sobre 182.754,98 €).

26. % Clientes Prioritarios sobre En Riesgo

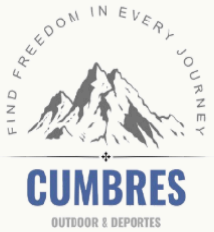
Validación: 30,1% (81 de 269).

Las medidas 24 y 25 frente a la 26 sostienen la lectura del capítulo 8: el 30% de los clientes en riesgo concentra el 62,7% de su facturación histórica.

Nota arquitectónica

Separación de responsabilidades entre las tres páginas del dashboard. La página 1 es dinámica: opera sobre la tabla de transacciones, responde al slicer de año y concentra las seis medidas de la carpeta Core. La página 2 es un snapshot: opera sobre clientes_rfm, no expone slicer de año y usa las medidas de las carpetas Churn and Retention y RFM, más Ticket Medio de la carpeta Core. La página 3 es también un snapshot y usa las ocho medidas de la carpeta Priorización.

Por qué la neutralización del contexto es crítica. La segmentación RFM es una fotografía, no una película: representa el estado de la base de clientes en la fecha de referencia 2026-01-01. Conectarla a un slicer temporal produce resultados sin significado (medida 13). Conectarla al slicer de tienda produce un error distinto y menos visible: un mismo cliente opera en varias plazas y cualquier conteo desglosado lo registra varias veces (apartado 9.1). Las medidas 9, 10 y 13 neutralizan ambos contextos de forma explícita; las medidas 7, 11, 14, 15, 17 y 18 no lo requieren porque operan sobre columnas de clientes_rfm que los filtros no alcanzan, y se verificó su estabilidad. La medida 8 se deriva de las medidas 9 y 10 y hereda su neutralización. Las medidas 12 y 16 neutralizan el contexto temporal y conservan el de tienda, que es el único desglose legítimo por tratarse de métricas de facturación.



FIN DEL INFORME

Customer Analytics · Cumbres Outdoor & Deportes

Martina Cottura
Proyecto End-to-End · Julio 2026